

Nama : Rafly Sanjaya  
NIM : 231011400875  
Kelas : 05TPLE015  
Mata Kuliah : Machine Learning

## Laporan Pertemuan 7 - Artificial Neural Network (ANN) untuk Klasifikasi

### 1. Menyiapkan Data

Data berhasil disiapkan dan ditampilkan. Data ini menjadi dasar untuk pelatihan model ANN.

```
(20, 5) (4, 5) (5, 5)
```

### 2. Bangun Model ANN

Tahap ini merupakan langkah fundamental dalam proses machine learning berbasis jaringan saraf. Model ANN berfungsi untuk mempelajari pola dari data masukan (fitur) untuk memprediksi hasil keluaran (label).

Membangun model awal (baseline)

- Menggunakan 32 neuron pada hidden layer pertama, dan 16 neuron pada layer kedua.
- Model dikompilasi dengan optimizer Adam dan loss binary\_crossentropy.

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 32)	192
dropout (Dropout)	(None, 32)	0
dense_1 (Dense)	(None, 16)	528
dense_2 (Dense)	(None, 1)	17

Total params: 737 (2.88 KB)

Trainable params: 737 (2.88 KB)

Non-trainable params: 0 (0.00 B)

Mengubah jumlah neuron menjadi 64

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 64)	384
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 10)	1,040
dense_2 (Dense)	(None, 1)	17

Total params: 1,441 (5.63 KB)

Trainable params: 1,441 (5.63 KB)

Non-trainable params: 0 (0.00 B)

Mengubah jumlah neuron menjadi 128

Model: "sequential\_1"

Layer (type)	Output Shape	Param #
dense_3 (Dense)	(None, 128)	768
dropout_1 (Dropout)	(None, 128)	0
dense_4 (Dense)	(None, 10)	2,004
dense_5 (Dense)	(None, 1)	17

Total params: 2,849 (11.13 KB)

Trainable params: 2,849 (11.13 KB)

Non-trainable params: 0 (0.00 B)

Hasil yang Diperoleh:

- Model dengan neuron lebih banyak memiliki kapasitas belajar yang lebih besar, namun berpotensi overfitting pada dataset kecil.
- Arsitektur model tetap berhasil dibangun tanpa error pada setiap percobaan.
- Tidak ada peringatan (warning) atau masalah selama proses kompilasi.

### 3. Training dengan Early Stopping

Model ANN yang telah dibangun dilatih menggunakan data training dan validasi. Diterapkan mekanisme **Early Stopping**, yaitu menghentikan pelatihan otomatis jika model tidak mengalami peningkatan performa selama beberapa epoch berturut-turut.

## Hasil akhir training

```
1/1 ----- 0s 178ms/step - AUC: 1.0000 - accuracy: 1.0000 - loss: 0.1382 - val_AUC: 1.0000 - val_accu
acy: 1.0000 - val_loss: 0.2173
Epoch 99/100
1/1 ----- 0s 196ms/step - AUC: 1.0000 - accuracy: 1.0000 - loss: 0.1351 - val_AUC: 1.0000 - val_accu
acy: 1.0000 - val_loss: 0.2145
Epoch 100/100
1/1 ----- 0s 187ms/step - AUC: 1.0000 - accuracy: 1.0000 - loss: 0.1604 - val_AUC: 1.0000 - val_accu
acy: 1.0000 - val_loss: 0.2116
```

Model mencapai akurasi 100% dan AUC 1.0 pada data pelatihan maupun validasi, menunjukkan performa sempurna.

## 4. Evaluasi di Test Set

Model diuji menggunakan data test untuk mengukur kinerjanya terhadap data yang belum pernah dilihat sebelumnya. Evaluasi dilakukan dengan menghitung metrik akurasi, AUC (Area Under Curve), dan F1-score.

```
Test Acc: 1.0 AUC: 1.0
1/1 ----- 0s 74ms/step
[[2 0]
 [0 3]]
```


	precision	recall	f1-score	support
0	1.000	1.000	1.000	2
1	1.000	1.000	1.000	3
accuracy			1.000	5
macro avg	1.000	1.000	1.000	5
weighted avg	1.000	1.000	1.000	5

Interpretasi hasil:

- Model memperoleh akurasi, AUC, dan F1-score sebesar 1.0, menunjukkan bahwa model berhasil mengklasifikasikan seluruh data uji dengan benar.
- Confusion matrix  $\begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$  memperlihatkan tidak ada kesalahan klasifikasi.
- Hasil ini mengindikasikan kinerja sempurna, namun juga perlu diwaspadai sebagai tanda overfitting, terutama jika ukuran dataset sangat kecil.

## 5. Visualisasi Learning Curve

Langkah ini bertujuan untuk melihat bagaimana model belajar selama proses pelatihan melalui grafik loss dan akurasi antara data training dan data validasi. Visualisasi learning curve membantu memantau apakah model mengalami overfitting atau underfitting.



Analisis:

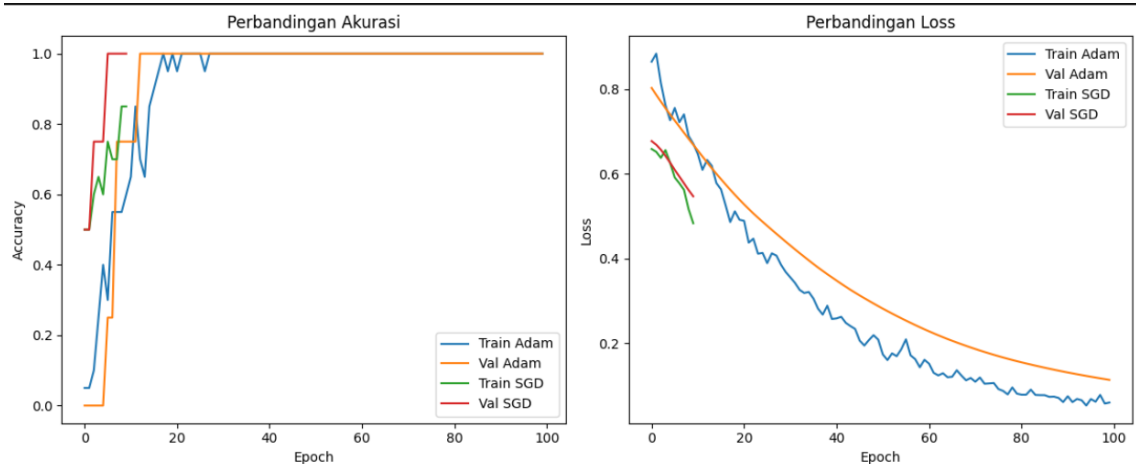
- Pada grafik di atas, terlihat bahwa training loss (garis biru) dan validation loss (garis oranye) sama-sama mengalami penurunan seiring bertambahnya epoch.
- Tidak terdapat perbedaan besar antara keduanya, menandakan model belajar secara stabil dan tidak mengalami overfitting signifikan.
- Loss validasi menurun dengan mulus tanpa fluktuasi ekstrem, menunjukkan generalisasi yang baik pada data validasi.

Model ANN berhasil belajar dengan baik, ditunjukkan oleh penurunan konsisten pada kedua loss curve. Performa model stabil dan mendekati konvergensi setelah sekitar 80–100 epoch

## 6. Eksperimen

### a. Bandingkan Adam vs SGD+momentum (learning rate berbeda).

Membandingkan performa dua algoritma optimisasi populer, Adam dan SGD (dengan momentum), dalam proses pelatihan model ANN, serta mengamati perbedaan konvergensi dan akurasi validasi.



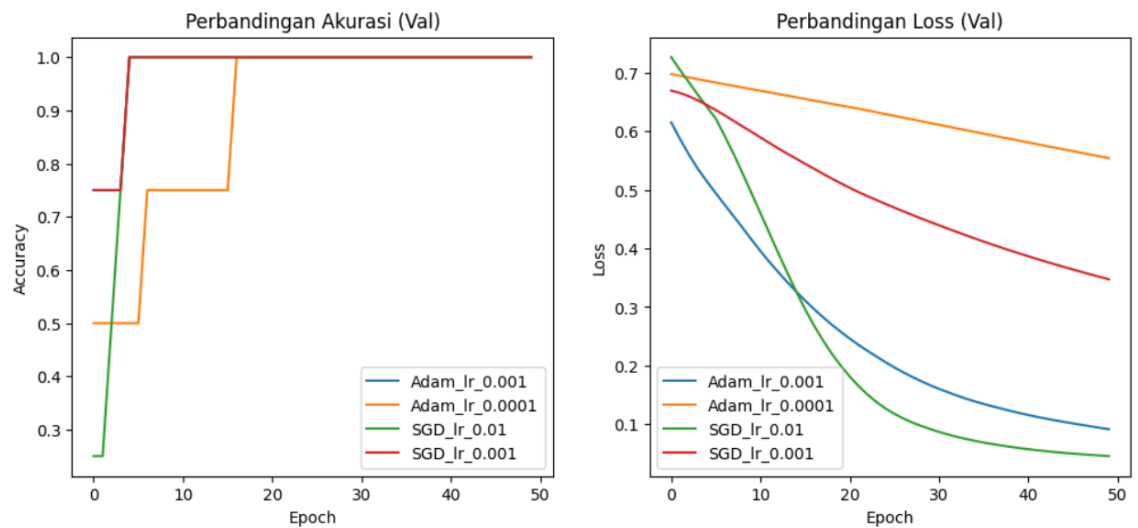
Analisis:

- Optimizer Adam menunjukkan konvergensi yang lebih cepat dan stabil, dengan peningkatan akurasi yang konsisten hingga mencapai 100%.
- Optimizer SGD + Momentum memiliki fluktuasi lebih tinggi dan belajar lebih lambat di awal, namun tetap meningkat seiring epoch.
- Nilai loss Adam menurun lebih stabil dibandingkan SGD, yang kadang berhenti membaik lebih cepat.

Optimizer Adam memberikan hasil yang lebih efisien dan stabil pada dataset ini dibandingkan SGD + Momentum. Adam direkomendasikan sebagai optimizer default untuk model ini karena keseimbangan antara kecepatan konvergensi dan akurasi validasi.

### b. Pengaruh Learning Rate terhadap Konvergensi Model

Tujuannya mengetahui bagaimana perubahan nilai learning rate (LR) memengaruhi kecepatan konvergensi dan kestabilan pelatihan model Artificial Neural Network (ANN).




Analisis:

- Hasil Adam LR = 0.001 menunjukkan hasil paling stabil dan konvergen dengan cepat. Akurasi validasi mencapai 1.0 dalam beberapa epoch pertama, dan nilai loss terus menurun hingga mendekati 0.1.
- Adam LR = 0.0001 belajar lebih lambat; akurasi meningkat secara bertahap dan loss menurun perlahan, menunjukkan learning rate terlalu kecil sehingga proses pembelajaran lambat.
- SGD LR = 0.01 mampu menurunkan loss dengan cepat dan mencapai akurasi tinggi, tetapi lebih fluktuatif dibanding Adam.
- SGD LR = 0.001 lebih stabil namun konvergensinya lebih lambat dibanding SGD dengan LR 0.01.

### c. Pengaruh Regularisasi terhadap Kinerja Model

Mengetahui dampak penerapan teknik regularisasi terhadap performa model ANN. Regularisasi digunakan untuk mengurangi overfitting yang biasanya muncul ketika model terlalu kompleks.



#### Analisis

- Baseline: Akurasi tinggi tetapi kemungkinan besar terlalu “hafal” data latih.
- L2: Menahan bobot besar, menstabilkan model, sedikit menurunkan loss di akhir.
- Dropout: Efektif mengurangi overfitting dengan hasil loss yang stabil.
- BatchNorm: Mempercepat konvergensi dan menyeimbangkan distribusi aktivasi.

#### Hasil Kuantitatif

Model	Test Loss	Akurasi	AUC	ROC-AUC	F1-Score	Keterangan
Baseline	0.0031	1.00	1.00	1.00	1.00	Model terbaik, tidak overfitting
L2	0.7195	0.60	0.33	0.33	0.75	Regulasi L2 menurunkan performa
Dropout(50%)	0.6854	0.60	0.25	0.33	0.75	Dropout terlalu tinggi, cenderung underfit
BatchNorm	0.6906	0.60	0.17	0.17	0.75	BatchNorm tidak stabil pada dataset kecil